

Segmentation de la clientèle d'un centre commercial

Comparaison de la Classification Ascendante Hiérarchique (CAH) et de la méthode des centroïdes (K-means)

19 août 2026

Abstract

Ce rapport présente une analyse de segmentation de la clientèle réalisée sur le jeu de données *Mall Customer Dataset* (Kaggle), constitué de 200 clients décrits par leur âge, leur revenu annuel et un score de dépense attribué par le magasin. Deux approches de classification non supervisée sont mises en œuvre et comparées : la classification ascendante hiérarchique (méthode de Ward) et la méthode des centroïdes (K-means). Les deux méthodes convergent vers une segmentation en cinq groupes de clients, cohérente et fortement concordante (indice de Rand ajusté = 0,94), permettant de dresser des profils marketing exploitables.

Contents

1	Introduction	2
2	Analyse exploratoire des données	2
3	Méthodologie	3
3.1	Classification Ascendante Hiérarchique (CAH)	3
3.2	Méthode des centroïdes (K-means)	3
3.3	Choix du nombre de clusters	3
4	Résultats	4
4.1	Classification Ascendante Hiérarchique	4
4.2	Méthode des centroïdes (K-means)	5
4.3	Comparaison des deux méthodes	6
5	Profils des segments de clientèle	6
5.1	Interprétation des clusters	7
6	Discussion et limites	8
7	Conclusion	8

1 Introduction

L'objectif de cette étude est de segmenter la clientèle d'un centre commercial afin d'identifier des groupes homogènes de clients partageant des comportements d'achat similaires. Une telle segmentation permet, en pratique, d'adapter les stratégies marketing (ciblage publicitaire, programmes de fidélité, positionnement de l'offre) à chaque profil de clientèle.

Le jeu de données utilisé, le **Mall Customer Dataset**, est disponible sur Kaggle et comprend 200 observations décrites par les variables suivantes :

- **CustomerID** : identifiant du client ;
- **Genre** : sexe du client (Homme / Femme) ;
- **Age** : âge du client (en années) ;
- **Annual Income (k\$)** : revenu annuel estimé (en milliers de dollars) ;
- **Spending Score (1-100)** : score de dépense attribué par le magasin selon le comportement d'achat et les habitudes de consommation du client.

Deux méthodes de classification non supervisée sont comparées :

1. la **Classification Ascendante Hiérarchique (CAH)**, avec la méthode de Ward, qui minimise l'inertie intra-classe à chaque fusion ;
2. la méthode des **centroïdes (K-means)**, qui partitionne les données en k groupes en minimisant la distance des points à leur centroïde respectif.

2 Analyse exploratoire des données

Le jeu de données ne comporte aucune valeur manquante. Le tableau 1 résume les statistiques descriptives des variables numériques.

Table 1: Statistiques descriptives des variables numériques

Variable	Moyenne	Écart-type	Min	Max
Âge	38,9	14,0	18	70
Revenu annuel (k\$)	60,6	26,3	15	137
Score de dépense (1-100)	50,2	25,8	1	99

La clientèle est composée à 56% de femmes et 44% d'hommes. La figure 1 montre les distributions des trois variables numériques : l'âge présente une distribution étalée avec une concentration entre 25 et 40 ans, le revenu annuel est globalement symétrique autour de 60 k\$, et le score de dépense couvre uniformément l'ensemble de l'échelle 1-100, sans mode particulier.




Figure 1: Distributions de l'âge, du revenu annuel et du score de dépense

Pour la suite de l'analyse, les variables **Revenu annuel** et **Score de dépense** sont retenues comme base du clustering. Ce choix, classique sur ce jeu de données, permet une lecture directe et interprétable en deux dimensions, et fait apparaître une structure en groupes particulièrement nette (cf. section 4). Les variables sont centrées-réduites (standardisation Z-score) avant tout calcul de distance, afin d'éviter que le revenu (échelle 15–137) ne domine artificiellement le score de dépense (échelle 1–100).

3 Méthodologie

3.1 Classification Ascendante Hiérarchique (CAH)

La CAH construit itérativement une hiérarchie de partitions en fusionnant, à chaque étape, les deux groupes les plus proches, jusqu'à n'obtenir qu'un seul groupe. La méthode de **Ward** a été retenue comme critère d'agrégation : à chaque fusion, elle sélectionne la paire de clusters qui minimise l'augmentation de l'inertie intra-classe totale. Cette méthode est cohérente avec l'approche centroïde puisqu'elle repose, comme le K-means, sur une logique de minimisation de variance intra-groupe.

3.2 Méthode des centroïdes (K-means)

Le K-means partitionne directement les observations en k groupes en minimisant la somme des distances euclidiennes au carré entre chaque point et le centroïde de son groupe :

$$J = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

où μ_j est le centroïde (moyenne) du cluster C_j . L'algorithme alterne entre l'affectation des points au centroïde le plus proche et la mise à jour des centroïdes, jusqu'à convergence. Pour limiter le risque de convergence vers un optimum local, l'algorithme est initialisé 20 fois (`n_init=20`) et la meilleure solution (inertie minimale) est conservée.

3.3 Choix du nombre de clusters

Le nombre de clusters k a été déterminé conjointement par trois approches complémentaires :

- l'observation du dendrogramme et des sauts de distance lors des dernières fusions (CAH) ;
- la méthode du coude sur l'inertie intra-classe du K-means ;

- le score de silhouette, qui mesure la cohésion interne et la séparation entre clusters (valeurs proches de 1 = bonne séparation).

4 Résultats

4.1 Classification Ascendante Hiérarchique

Le dendrogramme obtenu par la méthode de Ward (figure 2) met en évidence une structure claire en cinq groupes bien séparés. En observant les sauts de distance lors des dernières fusions (figure 3), on constate un écart net entre la fusion en 5 groupes et celle en 4 groupes, ce qui confirme visuellement $k = 5$ comme découpage naturel des données.




Figure 2: Dendrogramme de la CAH (méthode de Ward, distance euclidienne)




Figure 3: Évolution des distances de fusion – identification du saut justifiant $k = 5$

4.2 Méthode des centroïdes (K-means)

La figure 4 présente conjointement l'évolution de l'inertie intra-classe (méthode du coude) et du score de silhouette pour k variant de 2 à 10. L'inertie décroît fortement jusqu'à $k = 5$, où le score de silhouette atteint également son maximum (0,555), avant de diminuer pour des valeurs de k supérieures. Ces deux critères convergent donc vers $k = 5$ comme partition optimale, en cohérence avec les résultats de la CAH.




Figure 4: Méthode du coude et score de silhouette selon le nombre de clusters k

Le diagramme de silhouette détaillé pour $k = 5$ (figure 5) confirme une bonne qualité de partition : la quasi-totalité des observations présente un coefficient de silhouette positif, avec des clusters de largeurs comparables, à l'exception d'un cluster central un peu moins bien séparé (client au comportement de dépense « moyen »).




Figure 5: Diagramme de silhouette pour la partition K-means à 5 clusters

4.3 Comparaison des deux méthodes

La figure 6 superpose les partitions obtenues par la CAH et par le K-means sur le plan (Revenu annuel, Score de dépense), avec les centroïdes des clusters K-means matérialisés par des croix noires. Les deux méthodes identifient des groupes visuellement identiques, organisés en cinq zones du plan : quatre groupes situés aux extrémités (revenu/dépense faibles ou élevés) et un groupe central regroupant les profils « moyens ».




Figure 6: Comparaison des partitions obtenues par CAH (gauche) et K-means (droite)

Pour quantifier cette similarité, l'indice de Rand ajusté (*Adjusted Rand Index*, ARI) entre les deux partitions a été calculé : $ARI = 0,942$. Cette valeur, très proche de 1, indique une concordance quasi parfaite entre les deux approches, ce qui renforce la robustesse de la segmentation obtenue : elle ne dépend pas de la méthode de classification choisie, mais reflète une structure réelle et stable présente dans les données.

5 Profils des segments de clientèle

Les cinq clusters identifiés par la méthode K-means sont caractérisés dans le tableau 2 par leurs statistiques moyennes et leur poids dans l'échantillon. Les boxplots de la figure 7 illustrent la dispersion de l'âge, du revenu et du score de dépense au sein de chaque cluster.

Table 2: Profils moyens des clusters (K-means, $k = 5$)

Cluster	Âge moy.	Revenu moy.	Score dép. moy.	Effectif	%	% Femmes
0 – Standard	42,7	55,3 k\$	49,5	81	40,5%	59,3%
1 – Cible premium	32,7	86,5 k\$	82,1	39	19,5%	53,8%
2 – Impulsifs	25,3	25,7 k\$	79,4	22	11,0%	59,1%
3 – Économes aisés	41,1	88,2 k\$	17,1	35	17,5%	45,7%
4 – Prudents modestes	45,2	26,3 k\$	20,9	23	11,5%	60,9%




Figure 7: Distribution de l'âge, du revenu et du score de dépense par cluster

5.1 Interprétation des clusters

Cluster 0 – « Clients standards » (40,5% de la clientèle). Ce groupe, le plus nombreux, rassemble des clients d'âge moyen (43 ans), au revenu et au score de dépense proches de la moyenne générale (55 k\$ et 49,5). C'est le segment le plus hétérogène et le moins polarisé : il ne présente pas de comportement d'achat extrême et constitue le socle de la clientèle « ordinaire » du centre commercial.

Cluster 1 – « Clientèle cible / premium » (19,5%). Ces clients, relativement jeunes (33 ans en moyenne), combinent un revenu élevé (86,5 k\$) et un score de dépense élevé (82,1). Il s'agit du segment le plus stratégique : à fort pouvoir d'achat et forte propension à dépenser, ce groupe doit être prioritairement ciblé par les actions marketing premium, les nouveautés et les programmes de fidélisation.

Cluster 2 – « Jeunes dépensiers / impulsifs » (11%). Ce segment regroupe les clients les plus jeunes (25 ans en moyenne), avec un revenu faible (25,7 k\$) mais un score de dépense élevé (79,4). Ce profil, atypique, correspond probablement à de jeunes clients aux revenus encore limités mais avec une appétence marquée pour la consommation (achats impulsifs, sensibilité aux tendances, aux promotions et aux réseaux sociaux).

Cluster 3 – « Clients économes à revenu élevé » (17,5%). Ce groupe présente un revenu élevé (88,2 k\$), comparable au cluster 1, mais un score de dépense très faible (17,1). Ces clients disposent d'un fort pouvoir d'achat mais ne le mobilisent pas au sein du centre commercial étudié. Ce segment représente un potentiel de développement important : des actions ciblées (offres personnalisées, programme de fidélité, expérience d'achat premium) pourraient chercher à mieux capter leur budget.

Cluster 4 – « Clients prudents à revenu modeste » (11,5%). Les clients de ce groupe, plus âgés en moyenne (45 ans), combinent un revenu faible (26,3 k\$) et un score de dépense faible (20,9). Ce segment, cohérent avec un pouvoir d'achat limité, nécessite des actions différenciées (offres à prix réduit, promotions, produits d'appel) plutôt qu'une politique premium.

Sur le plan du genre, la répartition Homme/Femme reste globalement homogène entre les clusters (entre 46% et 61% de femmes), sans que le genre n'apparaisse comme un facteur discriminant majeur de la segmentation – ce qui est cohérent avec le fait que cette variable n'a pas été intégrée dans le calcul des distances.

6 Discussion et limites

La forte concordance entre la CAH et le K-means ($ARI = 0,94$) constitue un argument solide en faveur de la robustesse de la segmentation en cinq groupes. Les rares désaccords entre les deux méthodes concernent un nombre très limité d'observations situées à la frontière du cluster central (« Standard »), ce qui est attendu compte tenu du chevauchement partiel de ce groupe avec les segments voisins sur le plan (Revenu, Score de dépense).

Plusieurs limites doivent néanmoins être soulignées :

- le clustering repose uniquement sur deux variables (Revenu, Score de dépense) ; l'intégration de l'âge modifie sensiblement la structure des groupes (non présentée ici en détail) et pourrait affiner certains profils, notamment au sein du cluster 0 ;
- la nature exacte du *Spending Score* n'est pas documentée précisément dans le jeu de données (il s'agit d'un score construit par l'enseigne), ce qui limite l'interprétation économique fine de cette variable ;
- la taille de l'échantillon (200 clients) reste modeste ; une validation sur un échantillon plus large permettrait de consolider la stabilité des segments identifiés ;
- le K-means suppose des clusters de forme globalement sphérique dans l'espace standardisé, hypothèse ici vérifiée visuellement mais qui pourrait ne pas se généraliser à d'autres jeux de données.

7 Conclusion

L'application conjointe de la Classification Ascendante Hiérarchique et de la méthode des centroïdes (K-means) sur le *Mall Customer Dataset* conduit à une segmentation cohérente et robuste de la clientèle en cinq profils distincts, allant des clients premium à fort pouvoir d'achat et forte propension à dépenser, jusqu'aux profils économes à revenu élevé constituant un gisement de valeur inexploité. Cette double approche méthodologique, validée par un score de silhouette élevé (0,555) et une forte concordance inter-méthodes ($ARI = 0,94$), fournit une base solide pour orienter des actions marketing différenciées par segment de clientèle.